

Caracterizando a atividade de code review no GitHub

André Cota e Jhonatan Gutemberg

1464198@sga.pucminas.br | 1202002@sga.pucminas.br

Data: 7 de maio de 2026 | **Versão do Relatório:** 1.0

Link para repositório:

<https://github.com/andre-cota/LaboratorioExperimentacoesSoftware>

Conteúdo

1	Resumo	3
1.1	Qual hipótese foi testada	3
1.2	Principais resultados	3
1.3	Decisão recomendada	3
2	Contexto e Motivação	3
2.1	Problema de engenharia	3
2.2	Por que esse experimento é necessário agora	3
2.3	Restrições e riscos	3
3	Objetivos e Hipóteses	4
3.1	Objetivo específico	4
3.2	Hipótese Nula e Alternativa	4
3.3	Critérios de sucesso	4
4	Perguntas de Pesquisa	4
4.1	Dimensão A: Feedback Final das Revisões	4
4.2	Dimensão B: Número de Revisões	4
5	Variáveis e Métricas	5
5.1	Tabela de Métricas: Aceitação de PR	5
5.2	Tabela de Métricas: Número de Revisões	5
5.3	Guardrails	5
6	Desenho Experimental	6
7	Ambiente e Materiais	6
8	Procedimento (Passo a Passo)	6
9	Tratamentos e Baseline	6
9.1	Baseline	6
9.2	Tratamento	7

10 Análise de Dados	7
10.1 Método estatístico	7
10.2 Tratamento de outliers	7
11 Resultados	7
11.1 RQ01 – Size vs Feedback	7
11.2 RQ02 – Tempo de Análise vs Aceitação	8
11.3 RQ03 – Descrição vs Qualidade	8
11.4 RQ04 – Interações vs Qualidade	9
11.5 RQ05 – Tamanho do PR vs. Número de Revisões	10
11.6 RQ06 – Tempo de Análise vs. Número de Revisões	10
11.7 RQ07 – Descrição vs. Número de Revisões	10
11.8 RQ08 – Interações vs. Número de Revisões	10
12 Discussão e Interpretação	11
12.1 Explicação	11
12.2 Limitações	11
12.3 Trade-offs	11
13 Decisão e Recomendações	12
13.1 Decisão	12
13.2 Monitoramento pós-lançamento	12
14 Custos e impactos	12
14.1 Custo computacional	12
14.2 Risco técnico e operacional	12
15 Ética, Privacidade e Conformidade	12
16 Reprodutibilidade	12

1 Resumo

1.1 Qual hipótese foi testada

Variáveis de processo (tamanho do PR, tempo de análise e interações) influenciam a probabilidade de aprovação do código e o volume de revisões exigidas no code review.

1.2 Principais resultados

- **Tamanho:** Alterações volumosas no código enfrentam resistência clara. PRs extensos exigem maior esforço de revisão (mais ciclos) e possuem muito mais chances de rejeição, enquanto PRs pequenos são integrados com facilidade
- **Tempo de Análise:** A decisão de aprovar um PR costuma ser rápida (mediana de 28,4 horas). PRs que permanecem abertos por longos períodos (mediana de 93,8 horas) acabam rejeitados, possivelmente pela perda de contexto ou falta de consenso entre revisores
- **Tamanho da Descrição:** Contrariando a hipótese de que mais detalhes facilitariam a aprovação, os dados revelaram que PRs rejeitados possuem descrições consideravelmente maiores (784 caracteres) do que os aceitos (603 caracteres). Isso indica que textos muito longos frequentemente tentam justificar códigos muito complexos ou polêmicos

1.3 Decisão recomendada

Recomenda-se a implementação de políticas de *Small Pull Requests* nos fluxos de trabalho, visando reduzir o esforço cognitivo do revisor e acelerar o ciclo de feedback. Adicionalmente, as equipes devem monitorar PRs que ultrapassem as primeiras 48 horas de análise sem uma decisão.

2 Contexto e Motivação

2.1 Problema de engenharia

O principal desafio reside na identificação de variáveis que influenciam o sucesso ou o fracasso de um Pull Request. Contribuições extensas podem sobrecarregar os revisores, levando a tempos de análise excessivos ou à rejeição do código (CLOSED).

2.2 Por que esse experimento é necessário agora

Com o crescimento acelerado de projetos *open-source*, entender a dinâmica das revisões é crucial. O uso de automações mascara o comportamento humano, tornando necessária uma análise que filtre apenas interações significativas.

2.3 Restrições e riscos

- **Cotas da API:** Limites rígidos de taxa (*rate limits*) no GraphQL do GitHub.

- **Qualidade dos Metadados:** Dependência da consistência de preenchimento dos campos *bodyText*.
- **Filtros de Bots:** Risco de incluir revisões automáticas, mitigado pelo filtro de tempo mínimo (1 hora).

3 Objetivos e Hipóteses

3.1 Objetivo específico

Analisar a atividade de *code review* nos 200 repositórios mais populares do GitHub para identificar quais variáveis influenciam o resultado final e o esforço de revisão de um PR.

3.2 Hipótese Nula e Alternativa

- **Hipótese Nula (H_0):** Não há correlação significativa entre as métricas de processo (tamanho, tempo, interações) e o status final ou número de revisões do PR.
- **Hipótese Alternativa (H_1):** Repositórios com maior atividade de revisão ou PRs com grandes alterações de tamanho tendem a exigir um maior número de ciclos de revisão e possuem maior probabilidade de rejeição.

3.3 Critérios de sucesso

Encontrar correlações estatisticamente válidas ($p\text{-valor} < 0.05$).

4 Perguntas de Pesquisa

4.1 Dimensão A: Feedback Final das Revisões

- **RQ 01.** Qual a relação entre o tamanho dos PRs e o feedback final das revisões?
- **RQ 02.** Qual a relação entre o tempo de análise dos PRs e o feedback final?
- **RQ 03.** Qual a relação entre a descrição dos PRs e o feedback final?
- **RQ 04.** Qual a relação entre as interações nos PRs e o feedback final?

4.2 Dimensão B: Número de Revisões

- **RQ 05.** Qual a relação entre o tamanho dos PRs e o número de revisões realizadas?
- **RQ 06.** Qual a relação entre o tempo de análise dos PRs e o número de revisões?
- **RQ 07.** Qual a relação entre a descrição dos PRs e o número de revisões?
- **RQ 08.** Qual a relação entre as interações nos PRs e o número de revisões?

5 Variáveis e Métricas

As métricas coletadas para responder às questões de pesquisa foram divididas em dois quadros, representando as duas dimensões do nosso estudo.

5.1 Tabela de Métricas: Aceitação de PR

Tabela 1: Quadro Aceitação de PR

RQ	Métrica	Justificativa
RQ01	Quantidade de linhas adicionadas e deletadas, arquivos alterados e tamanho.	PRs grandes são complexos e difíceis de inspecionar.
RQ02	Tempo de análise.	PRs problemáticos tendem a ficar abertos por mais tempo.
RQ03	Tamanho da mensagem.	Descrições detalhadas facilitam o entendimento do revisor.
RQ04	Participantes, comentários e interações.	Maior colaboração pode indicar refinamento da solução.

5.2 Tabela de Métricas: Número de Revisões

Tabela 2: Quadro Número de revisões

RQ	Métrica	Justificativa
RQ05	Tamanho (<i>size</i>) e revisões (<i>reviews</i>).	Mudanças extensas demandam maior esforço de revisão.
RQ06	Tempo de análise em horas (<i>analysis_time_h</i>) e revisões.	O aumento de revisões amplia o tempo total de análise.
RQ07	Tamanho do texto (<i>body_len</i>) e revisões.	Descrições vagas podem gerar ciclos extras de revisão.
RQ08	Interações (<i>interactions</i>) e revisões.	Mais interações costumam indicar ciclos de revisão maiores.

5.3 Guardrails

Para garantir a validade estatística e a qualidade dos dados brutos coletados via API do GitHub, foram estabelecidos os seguintes *guardrails*:

- **Filtro de Automação (Tempo Mínimo):** Foram incluídos apenas *Pull Requests* com tempo de análise superior a 1 hora. Este *guardrail* é fundamental para excluir PRs aprovados instantaneamente por *bots* ou ferramentas de CI/CD, garantindo que o estudo foque na interação humana.
- **Filtro de Relevância (Revisão Mínima):** Apenas PRs com pelo menos 1 revisão formal registrada foram mantidos. Isso evita a inclusão de contribuições triviais que foram aceitas sem passar pelo processo de inspeção de código.

- **Controle de População (Mínimo por Repositório):** Somente repositórios que apresentaram no mínimo 100 *Pull Requests* válidos foram considerados.
- **Tratamento de Outliers:** Optou-se pelo uso de medianas em vez de médias e pelo teste de correlação de Spearman.
- **Amostragem Estatística:** Aplicação de uma amostra com 95% de confiança e 5% de margem de erro.

6 Desenho Experimental

- **Tipo:** Benchmark observacional.
- **Unidades:** *Pull Requests* (PRs).
- **População e Tamanho de Amostra:** 200 repositórios mais populares do GitHub.
- **Critérios de inclusão/exclusão:**
 - Apenas repositórios com ≥ 100 PRs (Merged/Closed).
 - Apenas PRs com pelo menos 1 revisão.
 - Apenas PRs com tempo de fechamento > 1 hora.

7 Ambiente e Materiais

- **Hardware:** Intel(R) Core (TM) i3-8130U CPU @ 2.20GHz
- **Software:** VSCode, Python, API GraphQL do GitHub.
- **Dataset:** Dados agregados a serem exportados para arquivo `.csv`.

8 Procedimento (Passo a Passo)

1. Executar *query* GraphQL para listar os 200 repositórios mais populares.
2. Extrair os PRs (MERGED/CLOSED) de cada repositório.
3. Aplicar filtros operacionais (remover bots validando tempo $> 1h$).
4. Agrupar e calcular a mediana das métricas (tamanho, tempo, descrição, interações).
5. Gerar gráficos de dispersão e matriz de correlação estatística.

9 Tratamentos e Baseline

9.1 Baseline

PRs de pequeno porte com baixas taxas de interação, que representam fluxos de entrega normais.

9.2 Tratamento

Comparação de como o status do PR e o volume de revisões se comportam conforme o tamanho e as interações aumentam progressivamente.

10 Análise de Dados

10.1 Método estatístico

Como a distribuição de dados de repositórios raramente possui distribuição estritamente normal, será utilizado um Teste de Correlação (Pearson ou Spearman, a depender da normalidade verificada) utilizando a mediana geral dos PRs.

10.2 Tratamento de outliers

Remoção de PRs automatizados (fechados em menos de 1 hora) e filtragem das medidas centrais.

11 Resultados

11.1 RQ01 – Size vs Feedback

A análise dos dados demonstrou que o tamanho das alterações é um fator determinante para o sucesso da integração de um código. Observou-se que Pull Requests com o status MERGED possuem uma concentração significativamente maior em valores baixos de linhas alteradas. Em contraste, os PRs com status CLOSED apresentam uma dispersão muito maior e a presença de diversos outliers de grande escala, sugerindo que contribuições volumosas enfrentam maior resistência ou dificuldade de revisão, resultando frequentemente em rejeição.




Figura 1: Gráfico representando a RQ01: Tamanho do PR vs Status.

11.2 RQ02 – Tempo de Análise vs Aceitação

A análise dos dados para a RQ02 demonstrou que a agilidade no ciclo de revisão é um forte indicador do desfecho de um Pull Request. Observou-se que a mediana do tempo de análise para PRs aceitos (MERGED) é de 28,4 horas, enquanto para PRs rejeitados (CLOSED) esse valor sobe para 93,8 horas.

Conforme ilustrado no gráfico de boxplot, revela-se que PRs integrados com sucesso costumam ter uma tomada de decisão muito mais célere. Em contrapartida, PRs que permanecem abertos por longos períodos apresentam uma tendência maior à rejeição, possivelmente devido à perda de contexto, obsolescência do código ou falta de consenso entre os revisores. A presença de diversos outliers de alto valor na categoria CLOSED reforça que a demora excessiva no processo de code review correlaciona-se negativamente com a aceitação da contribuição.




Figura 2: Boxplot comparando o tempo de análise (em horas) com o status final do Pull Request (CLOSED ou MERGED).

11.3 RQ03 – Descrição vs Qualidade

A análise da RQ03 buscou verificar se descrições mais detalhadas favorecem a aceitação de um código. Os resultados mostram que os Pull Requests aceitos (MERGED) possuem uma mediana de caracteres em sua descrição (603 caracteres) inferior à dos PRs rejeitados (784 caracteres).

Embora a hipótese inicial sugerisse que descrições maiores facilitariam o entendimento do revisor e aumentariam a taxa de aceite, os dados indicam uma realidade distinta. PRs rejeitados tendem a apresentar descrições mais longas, o que pode refletir a necessidade de explicar alterações excessivamente complexas, polêmicas ou que geraram muitas dúvidas durante o ciclo de revisão. Além disso, a presença de extensos outliers na categoria CLOSED reforça que a extensão do texto, por si só, não garante a integração do código se a alteração técnica subjacente não for considerada adequada pelos revisores.




Figura 3: Boxplot ilustrando a distribuição do tamanho da descrição (em caracteres) em relação ao desfecho do Pull Request.

11.4 RQ04 – Interações vs Qualidade

A análise da RQ04 focou em medir como o volume de interações influencia o desfecho de um código submetido. Os dados revelam que Pull Requests aceitos (MERGED) possuem uma mediana de interações menor do que os Pull Requests rejeitados (CLOSED).

Observa-se que um volume moderado de interações está associado ao sucesso da integração. Em contrapartida, os PRs rejeitados apresentam uma concentração maior de comentários e participantes, além de diversos outliers com números de interações muito elevados. Esse fenômeno sugere que discussões prolongadas, debates técnicos extensos ou falta de consenso entre os colaboradores tendem a preceder o fechamento do PR sem o merge. Portanto, embora o engajamento seja essencial para o refinamento da solução, interações excessivas podem ser um indicador de que a contribuição enfrenta dificuldades técnicas ou conceituais que inviabilizam sua aceitação.




Figura 4: Boxplot demonstrando o volume de interações (soma de comentários e participantes) comparado ao status final do Pull Request.

11.5 RQ05 – Tamanho do PR vs. Número de Revisões

A análise da RQ05 buscou identificar se o volume de código influencia a quantidade de revisões formais. Os dados revelaram uma correlação positiva moderada de 0,30. Este resultado confirma que Pull Requests mais extensos tendem a exigir um esforço maior de inspeção, resultando em um número elevado de revisões para garantir a integridade do código (referência visual: cruzamento 'size' e 'reviews' na Matriz de Correlação).

11.6 RQ06 – Tempo de Análise vs. Número de Revisões

Para a RQ06, verificou-se a relação entre o tempo de abertura do PR e o ciclo de revisões. A correlação encontrada foi fraca (0,16). Isso indica que, embora PRs que fiquem abertos por mais tempo possam receber mais revisões, o tempo de análise isolado não é o principal fator que atrai novos revisores nos repositórios estudados.

11.7 RQ07 – Descrição vs. Número de Revisões

A RQ07 investigou se o tamanho da descrição impacta o engajamento dos revisores. O coeficiente de Spearman foi de 0,18, indicando uma correlação fraca. Conclui-se que descrições mais longas não garantem necessariamente um aumento no número de revisões formais, sugerindo que outros fatores técnicos são mais relevantes para atrair revisores.

11.8 RQ08 – Interações vs. Número de Revisões

A análise da RQ08 mostrou uma correlação positiva moderada de 0,30 entre o volume de interações (comentários e participantes) e o número de revisões. Este resultado é esperado, pois ciclos de revisão formais geram naturalmente mais debates e engajamento entre os colaboradores do projeto.




Figura 5: Matriz de Correlação de Spearman apresentando as relações entre variáveis de processo e o esforço de revisão (reviews).

12 Discussão e Interpretação

12.1 Explicação

Os dados evidenciam que características sob controle do desenvolvedor, como o tamanho do PR e o nível de detalhamento descritivo, moldam ativamente o fluxo de aprovação. Em repositórios abertos, a simplicidade e a rapidez de comunicação são cruciais para que o *code review* não se torne um gargalo.

12.2 Limitações

A análise limitou-se à validação quantitativa das interações e tamanhos de código, não avaliando o aspecto qualitativo dos comentários. Ou seja, não foi distinguido se um comentário era um elogio, uma dúvida de arquitetura ou a identificação de um *bug*.

12.3 Trade-offs

Projetos que exigem descrições longas e múltiplas interações visam aumentar a segurança e qualidade final do código integrado, porém, pagam o preço de um ciclo de *delivery* mais engessado e com taxas de rejeição potencialmente maiores.

13 Decisão e Recomendações

13.1 Decisão

Recomenda-se a implementação de políticas de *Small Pull Requests* nos fluxos de trabalho. A quebra de PRs extensos deve ser adotada.

13.2 Monitoramento pós-lançamento

Integrar validações no *pipeline* para emitir alertas caso a revisão de um PR ultrapasse 48 horas, além de limitar PRs com escopos ambíguos.

14 Custos e impactos

14.1 Custo computacional

A extração inicial de dados brutos de apenas 5% dos repositórios demandou aproximadamente 12 horas de execução. Diante dessa limitação, a adoção da amostragem com 95% de confiança mostrou-se a alternativa mais viável para otimizar o cronograma do estudo. Com a nova metodologia, o tempo de extração foi reduzido para cerca de 3 horas, enquanto o processamento e a análise dos dados coletados foram concluídos em apenas 10 minutos.

14.2 Risco técnico e operacional

O principal risco operacional reside na dependência da disponibilidade da API do GitHub. Apesar da implementação de estratégias de mitigação como o controle do tempo de execução, mecanismos de *retry* após falhas e redução do volume de dados por chamada, foram observados erros de servidor como HTTP 500 e 502. Tais instabilidades decorreram do elevado fluxo de dados e de interrupções intermitentes na própria infraestrutura da API, o que pode impactar a integridade da coleta caso não haja monitoramento constante.

15 Ética, Privacidade e Conformidade

Os dados são públicos sob licenças open-source. Nenhuma informação pessoal de desenvolvedores foi processada além dos metadados públicos dos repositórios.

16 Reprodutibilidade

Para que seja possível reproduzir o experimento, basta clonar nosso repositório do Github, configurar um token válido do GitHub (PAT) e executar o script principal.